

応用数学

「第1章：線形代数」

- ・ベクトルの変換 > 行列とベクトルの積で行う
- ・行列とベクトルの積 行列（横）× ベクトル（縦）
計算結果はベクトルの数と同じになる。

- ・固有値、固有ベクトル

複雑なベクトル計算がある特定の条件下では $A\vec{x} = \lambda\vec{x}$ で求められる。

この特殊なベクトルXとその係数λを、行列Aに対する固有ベクトル、固有値という。

- ・行列式～平行四辺形の面積と考えられる

複雑な行列～立体体の面積

- ・固有値分解～計算が楽になる。大きいデータをちいさくできる。

データを整理して表現できる。

行列Aが $\lambda_1, \lambda_2, \lambda_3$ をとるとき、この λ_n を対角線に並べた行列を作る。

$$A = \begin{pmatrix} \lambda_1 & & \\ & \lambda_2 & \\ & & \ddots \end{pmatrix}$$

これに固有ベクトル $V = \begin{pmatrix} \vec{v}_1 & \vec{v}_2 & \dots \end{pmatrix}$

を用意すると $AV = VA$

となる。左辺からVを消すためVの逆行列を掛ける。

このように正方形の行列を3つの行列の積に分解することを固有値分解という。

- ・特異値分解～正方行列以外（長方形）は固有値分解ではなく特異値分解で対応。

かけ算して正方行列を作り固有値分解の手法で解く。

特長の見えない行列の特長を見つけるのが特異値分解。

音声データや画像データで同じ特長を抽出したいときに特異値分解を使用。

「第2章：確率・統計」

- ・ 頻度確率～通常の確率
- ・ ベイズ確率～信念の度合の確率。主観確率。
- ・ 条件付き確率～ある事象 $X=x$ が与えられた下で $Y=y$ となる確率

$$P(Y=y \mid X=x) = P(Y=y, X=x) / P(X=x)$$

- ・ 独立な事象の同時確率～お互いの発生には因果関係のない事象 $X=x$ と事象 $Y=y$ が同時に発生する確率。

$$P(X=x, Y=y) = P(X=x)P(Y=y) = P(Y=y, X=x)$$

- ・ ベイズ則～事象Aが起こる条件のもとで、事象Bが起こる確率。

$$P(X=x \mid Y=y)P(Y=y) = P(Y=y \mid X=x)P(X=x)$$

- ・ 確率変数～事象と結びつけられた数値
- ・ 確率分布～事象の発生する確率の分布
- ・ 期待値～確率変数の平均値、またはありえそうな値

離散値：

連続値：

$$\begin{aligned} \text{期待値} E(f) \\ &= \sum_{k=1}^n P(X = x_k) f(X = x_k) \end{aligned}$$

$$\begin{aligned} \text{期待値} E(f) \\ &= \int P(X = x) f(X = x) dx \end{aligned}$$

- ・ 分散～データの各々の値が平均値からどれだけズレているかを表したもの

$$\begin{aligned} \text{分散} \text{Var}(f) \\ &= E \left(\left(f_{(X=x)} - E(f) \right)^2 \right) \\ &= E \left(f_{(X=x)}^2 \right) - \left(E(f) \right)^2 \end{aligned}$$

- ・ 共分散～2つのデータの系列の違い。正の値を取れば似た傾向。負の値を取れば似た傾向。ゼロをとれば関係性は乏しい。

$$\begin{aligned} \text{共分散} \text{Cov}(f, g) \\ &= E \left(\left(f_{(X=x)} - E(f) \right) \left(g_{(Y=y)} - E(g) \right) \right) \\ &= E(fg) - E(f)E(g) \end{aligned}$$

- ・ ベルヌーイ分布～コイントスのイメージ。2つしか値をとらない場合の分布。
離散値の確率分布。

$$P(x \mid \lambda) = \lambda^x (1 - \lambda)^{(1-x)} \text{ for } x \in \{0, 1\}$$

Takes a single parameter $\lambda \in [0, 1]$

- ・ マルチヌーイ分布～ベルヌーイ分布を一般化した離散値の確率分布。
2 つではなくN個の値をとる。

$$P(x | \lambda) = \prod_{i=0}^K \lambda_i^{x_i}$$

Takes K parameters $\lambda_i \in [0, 1]$ where $\sum_{i=1}^K \lambda_i = 1$

- ・ 二項分布～ベルヌーイ分布の多試行版。

$$P(x|\lambda, n) = \frac{n!}{x! (n-x)!} \lambda^x (1-\lambda)^{1-x}$$

- ・ ガウス分布～釣鐘型の連続分布。

最大値をとるまで緩やかに上昇し、最大値を超えると緩やかに下降。

$$\mathcal{N}(x; \mu, \sigma^2) = \sqrt{\frac{1}{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(x - \mu)^2\right)$$

$\exp(x)$ = ネイピア関数、微分しても値が変わらない。

「第3章：情報理論」

- ・ 自己情報量～対数の底が2 のとき単位はbit

公式のWは逆数、事象の数。e.g.) $\log(1/A) = -\log A$

\log は桁数の多い掛算を足し算で演算できるメリットがある。

e.g) $\log_2(A \times B) = \log_2 A + \log_2 B$

$$I(x) = -\log(P(x)) = \log(W(x))$$

対数の底がネイピアのとき単位はnat

- ・ シャノンエントロピー～平均情報量。自己情報量の期待値。自己エントピーとは別物。

$$H(P) = -\sum_{A \in \Omega} P(A) \log P(A)$$

- ・ KL ダイバージェンス～同じ事象・確率変数の異なる確率分布P、Qの違いを表す。

$$D_{\text{KL}}(P\|Q) = \mathbb{E}_{x \sim P} \left[\log \frac{P(x)}{Q(x)} \right] = \mathbb{E}_{x \sim P} [\log P(x) - \log Q(x)]$$

- ・ 交差エントロピー～KLダイバージェンスの一部を取り出し、PとQの平均を考える。

Qの自己情報量をPの分布で平均する。

$$H(P, Q) = H(P) + D_{\text{KL}}(P\|Q)$$

$$H(P, Q) = -\mathbb{E}_{x \sim P} \log Q(x)$$